МГТУ им. Н.Э. Баумана

Факультет "Информатика и системы управления" Кафедра "Системы обработки информации и управления"

дисциплина:

"Технологии машинного обучения"



Отчет по лабораторной работе №5
"Линейные модели, SVM и деревья решений"

Выполнил:

Студент группы ИУ5-61Б

Сукиасян В.М.

Преподаватель:

Гапанюк Ю.Е.

Цель лабораторной работы: изучение линейных моделей, SVM и деревьев решений.

Задание:

- 1. Выберите набор данных (датасет) для решения задачи классификации или регрессии.
- 2. В случае необходимости проведите удаление или заполнение пропусков и кодирование категориальных признаков.
- 3. С использованием метода train_test_split разделите выборку на обучающую и тестовую.
- 4. Обучите следующие модели:
 - одну из линейных моделей;
 - SVM;
 - дерево решений.
- 5. Оцените качество моделей с помощью двух подходящих для задачи метрик. Сравните качество полученных моделей.

Выполненная работа:

В данной лабораторной работе модели будут строиться для решения задачи классификации. Загрузка и первичный анализ данных. Формирование DataFrame:

```
In [2]: wine = load_wine()
In [3]: # Сформируем DataFrame
                   In [4]: wine_df.isnull().sum()
Out[4]: alcohol
                   malic\_acid
                   ash
                   alcalinity_of_ash
                   magnesium
                   total phenols
                   flavanoids
                   nonflavanoid_phenols
                   proanthocvaning
                   color_intensity
                   hue
                   od280/od315 of diluted wines
                    target
                   dtype: int64
In [5]: wine df.head

        Cobund method NDFrame.head of 0 14.23 1.71 2.43
        alcohol malic_acid ash 15.6 127.0
        alcalinity_of_ash magnesium total_phenols \ 0 2.80
        total_phenols \ 0 2.80

        1 13.20 1.78 2.14
        11.2 100.0
        2.65

        2 13.16 2.36 2.67
        18.6 101.0
        2.80

        3 14.37 1.95 2.50
        16.8 113.0
        3.85

        4 13.24 2.59 2.87
        21.0 118.0
        2.80

        ...
        ...
        ...
        ...

        173 13.71 5.65 2.45
        20.5 95.0
        1.68

        174 13.40 3.91 2.48
        23.0 102.0
        1.80

        175 13.27 4.28 2.26
        20.0 120.0
        1.59

        176 13.17 2.59 2.37
        20.0 120.0
        1.65

        177 14.13 4.10 2.74
        24.5 96.0
        2.05

Out[5]: <bound method NDFrame.head of
```

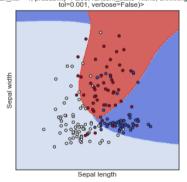
Разделение данных на обучающую и тестовую выборки. Построение модели «Логистическая регрессия»:

```
In [6]: def convert_target_to_binary(array:np.ndarray, target:int) -> np.ndarray:
                     # Если иелевой признак совпадает с указанным, то 1 иначе
                            res = [1 if x==target else 0 for x in array]
                            return res
  In [7]: bin_wine_y = convert_target_to_binary(wine.target, 2)
   In [8]: wine_X_train, wine_X_test, wine_y_train, wine_y_test = train_test_split(
                            wine.data, bin_wine_y, test_size=0.2, random_state=1)
  In [9]: cl1 = LogisticRegression()
 In [10]: cl1.fit(wine X train, wine v train)
                     c: \label{linear_model_logistic.py:940: Convergence Warning: lbfgs failed to conver
                    onverge (status=1):
STOP: TOTAL NO. of ITERATIONS REACHED LIMIT.
                    Increase the number of iterations (max_iter) or scale the data as shown in:
                    https://scikit-learn.org/stable/modules/preprocessing.html
Please also refer to the documentation for alternative solver options:
                       https://scikit-learn.org/stable/modules/linear_model.html#logistic-regression
extra_warning_msg=_LOGISTIC_SOLVER_CONVERGENCE_MSG)
Out[10]: LogisticRegression(C=1.0, class_weight=None, dual=False, fit_intercept=True,
                                                           intercept_scaling=1, 11 ratio=None, max_iter=100,
multi_class='auto', n_jobs=None, penalty='12',
random_state=None, solver='lbfgs', tol=0.0001, verbose=0,
                                                           warm_start=False)
 In [11]: pred_wine_y_test = cl1.predict(wine_X_test)
                    pred_wine_y_test
In [12]: pred_wine_y_test_proba = cl1.predict_proba(wine_X_test)
                    pred_wine_y_test_proba[:10]
Out[12]: array([[6.67502815e-02, 9.33249719e-01],
                                  [9.99028518e-01, 9.71481719e-04], [9.98580105e-01, 1.41989547e-03],
                                  [9.99003483e-01, 9.96517066e-04],
[9.88929037e-01, 1.10709626e-02],
                                  [4.53547396e-02, 9.54645260e-01], [9.54959671e-01, 4.50403288e-02], [9.98955423e-01, 1.04457706e-03],
                                  [7.08307657e-03, 9.92916923e-01],
[9.68840217e-01, 3.11597833e-02]])
In [13]: # Вероятность принадлежности к 0 классу
                    [round(x, 4) for x in pred_wine_y_test_proba[:10,0]]
Out[13]: [0.0668, 0.999, 0.9986, 0.999, 0.9889, 0.0454, 0.955, 0.999, 0.0071, 0.9688]
In [14]: # Вероятность принадлежности к 1 классу
                   [round(x, 4) for x in pred_wine_y_test_proba[:10,1]]
Out[14]: [0.9332, 0.001, 0.0014, 0.001, 0.0111, 0.9546, 0.045, 0.001, 0.9929, 0.0312]
In [15]: # Сумма вероятностей равна 1
                   pred_wine_y_test_proba[:10,0] + pred_wine_y_test_proba[:10,1]
Out[15]: array([1., 1., 1., 1., 1., 1., 1., 1., 1.])
In [16]: accuracy_score(wine_y_test, pred_wine_y_test)
Out[16]: 0.972222222222222
```

Построение модели «SVC»:

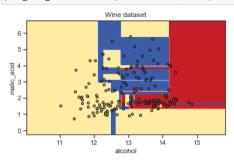
```
def plot_contours(ax, clf, xx, yy, **params):
    """Plot the decision boundaries for a classifier.
       ax: matplotlib axes object
      clf: a classifier
xx: meshgrid ndarray
       params: dictionary of params to pass to contourf, optional
       Z = clf.predict(np.c_[xx.ravel(), yy.ravel()])
      Z = Z.reshape(xx.shape)
#Можно проверить все ли метки классов предсказываются
       #print(np.unique(Z))
       out = ax.contourf(xx, yy, Z, **params)
      return out
def plot_cl(clf):
    title = clf._repr_
    clf.fit(wine_X, wine_y)
    fig, ax = plt.subplots(figsize=(5,5))
    X0, X1 = wine_X[:, 0], wine_X[:, 1]
      xx, yy = make_meshgrid(X0, X1)
plot_contours(ax, clf, xx, yy, cmap=plt.cm.coolwarm, alpha=0.8)
ax.scatter(X0, X1, c=wine_y, cmap=plt.cm.coolwarm, s=20, edgecolors='k')
      ax.set_xlim(xx.min(), xx.max())
ax.set_ylim(yy.min(), yy.max())
ax.set_xlabel('Sepal length')
ax.set_ylabel('Sepal width')
       ax.set xticks(())
       ax.set_yticks(()
       ax.set_title(title)
       plt.show()
```

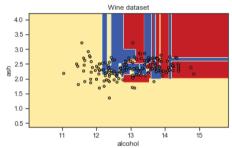
<bound method BaseEstimator.__repr__ of SVC(C=1.0, break_ties=False, cache_size=200, class_weight=None, coef0=0.0, decision_function_shape='ovr', degree=4, gamma=0.2. kernel='poly', max_iter=-1, probability=False, random_state=None, shrinking=True, tol=0.001, verbose=False)>



Построение модели «Дерево решений»:

In [26]: plot_tree_classification('Wine dataset', wine)





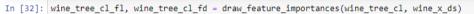
```
In [27]: wine_x_ds = pd.DataFrame(data=wine['data'], columns=wine['feature_names'])
wine_x_ds.head()
```

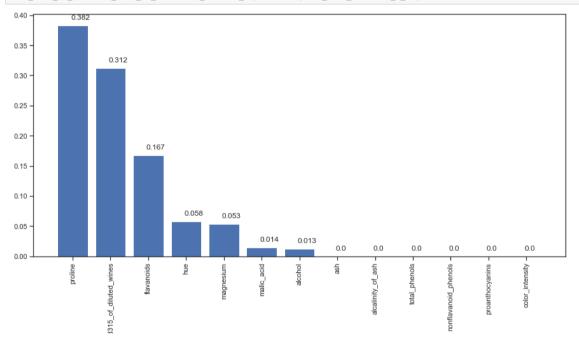
Out[27]:

		alcohol	malic_acid	ash	$alcalinity_of_ash$	magnesium	total_phenols	flavanoids	$nonflava noid_phenols$	proanthocyanins	color_intensity	hue	od280/od31
	0	14.23	1.71	2.43	15.6	127.0	2.80	3.06	0.28	2.29	5.64	1.04	
	1	13.20	1.78	2.14	11.2	100.0	2.65	2.76	0.26	1.28	4.38	1.05	
	2	13.16	2.36	2.67	18.6	101.0	2.80	3.24	0.30	2.81	5.68	1.03	
	3	14.37	1.95	2.50	16.8	113.0	3.85	3.49	0.24	2.18	7.80	0.86	
	4	13.24	2.59	2.87	21.0	118.0	2.80	2.69	0.39	1.82	4.32	1.04	
4													+

```
In [28]: # Обучим дерево на всех признаках wine
wine_tree_cl = DecisionTreeClassifier(random_state=1)
wine_tree_cl.fit(wine_x_ds, wine.target)
wine_tree_cl
```

```
In [29]: # Важность признаков
             list(zip(wine_x_ds.columns.values, wine_tree_cl.feature_importances_))
'ash', 0.0),
'alcalinity_of_ash', 0.0),
'magnesium', 0.0534597951279922),
                 'total_phenols', 0.0),
'flavanoids', 0.16704836491408806),
'nonflavanoid_phenols', 0.0),
                 'proanthocyanins', 0.0),
'color_intensity', 0.0),
'hue', 0.058185091460406506),
               ('od280/od315_of_diluted_wines', 0.3120425747831769),
('proline', 0.38247044986432716)]
In [30]: # Важность признаков в сумме дает единицу sum(wine_tree_cl.feature_importances_)
Out[30]: 1.0
In [31]: from operator import itemgetter
              def draw_feature_importances(tree_model, X_dataset, figsize=(15,7)):
                   Вывод важности признаков в виде графика
                   # Сортировка значений важности признаков по убыванию
list_to_sort = list(zip(X_dataset.columns.values, tree_model.feature_importances_))
sorted_list = sorted(list_to_sort, key=itemgetter(1), reverse = True)
                    # Названия признаков
                   # Назаания признаков
labels = [x for x,_ in sorted_list]
# Важности признаков
data = [x for _,x in sorted_list]
# Вывод графика
                    fig, ax = plt.subplots(figsize=figsize)
                   ind = np.arange(len(labels))
plt.bar(ind, data)
                    plt.xticks(ind, labels, rotation='vertical')
                    .
# Вывод значений
                    for a,b in zip(ind, data):
                         plt.text(a-0.05, b+0.01, str(round(b,3)))
                    plt.show()
                    return labels, data
```





```
In [33]: # Список признаков, отсортированный на основе важности, и значения важности
           wine_tree_cl_fl, wine_tree_cl_fd
Out[33]: (['proline',
               od280/od315_of_diluted_wines',
              'flavanoids',
              'magnesium'
               'malic acid'
              'alcohol',
               'ash'.
               'alcalinity_of_ash',
              'total_phenols'
              'nonflavanoid phenols'.
               'proanthocyanins',
             'color_intensity'],
[0.38247044986432716,
              0.3120425747831769,
              0.16704836491408806
              0.058185091460406506,
              0.0534597951279922,
              0.014223159778821876
              0.012570564071187309
              0.0.
              0.0,
              a a
             0.01)
 In [34]: wine_x_ds.head()
Out[34]:
               alcohol malic_acid ash alcalinity_of_ash magnesium total_phenols flavanoids nonflavanoid_phenols proanthocyanins color_intensity hue od280/od31
                         1.71 2.43
                                                                                                                              2.29
                13.20
                 13.16
                         2.36 2.67
                                                          101.0
                                                                              2.80
                                                                                         3.24
                                                                                                                               2.81
                                                                                                                                              5.68 1.03
                              1.95 2.50
                                                               113.0
                                                                              3.85
                                                                                                                                              7.80 0.86
             4 13.24
                         2.59 2.87
                                                   21.0
                                                          118.0
                                                                              2.80
                                                                                         2.69
                                                                                                              0.39
                                                                                                                               1.82
                                                                                                                                              4.32 1.04
           4
 In [35]: # Пересортируем признаки на основе важности
           wine_x_ds_sorted = wine_x_ds[wine_tree_cl_fl]
wine_x_ds_sorted.head()
Out[35]:
               proline od280/od315 of diluted wines flavanoids hue magnesium malic acid alcohol ash alcalinity of ash total phenols nonflavanoid phenols
            0 1065.0
                                                                                      1.71
                                              3.92
                                                         3.06 1.04
                                                                          127.0
                                                                                              14.23 2.43
                                                                                                                     15.6
                                                                                                                                   2.80
                                                                                                                                                         0.28
             1 1050.0
                                               3 40
                                                          2.76 1.05
                                                                           100.0
                                                                                       1.78
                                                                                              13 20 2 14
                                                                                                                     11.2
                                                                                                                                   2.65
                                                                                                                                                         0.26
            2 1185.0
                                               3.17
                                                         3.24 1.03
                                                                          101.0
                                                                                       2.36
                                                                                              13.16 2.67
                                                                                                                     18.6
                                                                                                                                   2.80
                                                                                                                                                         0.30
             3 1480.0
                                               3.45
                                                          3.49 0.86
                                                                           113.0
                                                                                       1.95
                                                                                              14.37 2.50
                                                                                                                     16.8
                                                                                                                                   3.85
                                                                                                                                                         0.24
                                                      2.69 1.04
             4 735.0
                                              2.93
                                                                          118.0
                                                                                      2.59 13.24 2.87
                                                                                                                     21.0
                                                                                                                                   2.80
                                                                                                                                                         0.39
 In [36]: # Разделим выборку на обучающую и тестовую
            wine_X_train, wine_X_test, wine_y_train, wine_y_test = train_test_split(
wine_x_ds_sorted, wine.target, test_size=0.5, random_state=1)
           wine_X_train.shape, wine_X_test.shape
Out[36]: ((89, 13), (89, 13))
 In [37]: # Обучим дерево и предскажем результаты на всех признаках
wine_tree_cl_feat_1 = DecisionTreeClassifier(random_state=1).fit(wine_X_train, wine_y_train)
wine_y_test_predict = wine_tree_cl_feat_1.predict(wine_X_test)
            wine_y_test_predict.shape
Out[37]: (89,)
In [38]: # Проверим точность по классам
           \verb|print_accuracy_score_for_classes(wine_y_test, wine_y_test_predict)|\\
           Метка
                     Accuracy
                     0.9393939393939394
                     0.8529411764705882
```

Таким образом, показатели метрики Accuracy говорят о высоком качестве всех построенных моделей.