МГТУ им. Н. Э. Баумана

кафедра ИУ5

курс «Технологии машинного обучения»

Рубежный контроль №2

«Технологии использования и оценки моделей машинного обучения»

Вариант 22

ВЫПОЛНИЛ:

Сукиасян В. М.

Группа ИУ5-61Б

ПРОВЕРИЛ:

Гапанюк Ю. Е.

Москва, 2020 г.

Номер варианта	Номер задачи	Номер набора данных, указанного в задаче
22	1	6

Задача №2. Кластеризация данных (по вариантам).

Кластеризуйте данные с помощью двух алгоритмов кластеризации (варианты по группам приведены в таблице):

Группа	Алгоритм №1	Алгоритм №2
ИУ5-61Б, ИУ5Ц-81Б	K-Means	DBSCAN

Сравните качество кластеризации с помощью следующих метрик качества кластеризации (если это возможно для Вашего набора данных):

1. Adjusted Rand index
2. Adjusted Mutual Information
3. Homogeneity, completeness, V-measure
4. Коэффициент силуэта

Сделайте выводы о том, какой алгоритм осуществляет более качественную кластеризацию на Вашем наборе данных.

Наборы данных:

6. https://www.kaggle.com/mohansacharya/graduate-admissions
файл *Admission_Predict.csv*

Выполнение работы

In [377]:
```
import warnings
from sklearn.cluster import KMeans, DBSCAN
from sklearn.metrics import *
from sklearn.preprocessing import StandardScaler
from sklearn.model_selection import train_test_split

import itertools
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

Загрузка данных

In [378]:
```
data = pd.read_csv('../data/Admission_Predict.csv', sep=",")
```

In [379]:
```
dataset_name = "Admission Predict"
data.shape
```

Out[379]: (400, 9)

In [380]:
```
data.dtypes
```

Out[380]:
```
Serial No.             int64
GRE Score              int64
TOEFL Score            int64
University Rating      int64
SOP                  float64
LOR                  float64
CGPA                 float64
Research               int64
Chance of Admit      float64
dtype: object
```

In [381]:
```
data.head()
```

Out[381]:

	Serial No.	GRE Score	TOEFL Score	University Rating	SOP	LOR	CGPA	Research	Chance of Admit
0	1	337	118	4	4.5	4.5	9.65	1	0.92
1	2	324	107	4	4.0	4.5	8.87	1	0.76
2	3	316	104	3	3.0	3.5	8.00	1	0.72
3	4	322	110	3	3.5	2.5	8.67	1	0.80
4	5	314	103	2	2.0	3.0	8.21	0	0.65

Характеристики датасета для кластеризации

In [382]:
```
# Выбрано 2 числовых признака
cluster_dataset = pd.DataFrame(columns=['GRE Score', 'TOEFL Score'])
cluster_dataset['GRE Score'] = data['GRE Score']
cluster_dataset['TOEFL Score'] = data['TOEFL Score']
```

In [383]:
```
cluster_dataset.shape
```

Out[383]:
```
(400, 2)
```

In [384]:
```
cluster_dataset
```

Out[384]:

	GRE Score	TOEFL Score
0	337	118
1	324	107
2	316	104
3	322	110
4	314	103
...	...	...
395	324	110
396	325	107
397	330	116
398	312	103
399	333	117

400 rows × 2 columns

In [385]:
```
cluster_true_y = data['Research']
```

In [386]:
```
cluster_true_y
```

Out[386]:
```
0      1
1      1
2      1
3      1
4      0
      ..
395    1
396    1
397    1
398    0
399    1
Name: Research, Length: 400, dtype: int64
```

In [387]:
```
print(np.unique(cluster_true_y))
```

```
[0 1]
```

Визуализация кластеров

In [388]:
```
cluster_n_samples = 400

def visualize_clusters(cluster_dataset, cluster_result):
    """
    Визуализация результатов кластерного анализа
    """
    plt.subplots(figsize=(15,15))
    plot_num = 0
    plot_num += 1
    plt.subplot(2, 3, plot_num)
    # Цвета точек как результат кластеризации
    colors = pd.np.array(list(itertools.islice(itertools.cycle(['#377eb8', '#ff7f00', '#4daf4a',
                                                '#f781bf', '#a65628', '#984ea3',
                                                '#999999', '#e41a1c', '#dede00']),
                                         int(max(cluster_result) + 1))))
    # черный цвет для выделяющихся значений
    colors = np.append(colors, ["#000000"])
    plt.scatter(cluster_dataset['GRE Score'], cluster_dataset['TOEFL Score'], s=3, color=colors[cluster_result])
    plt.xticks(())
    plt.yticks(())
    plt.title(dataset_name)

    plt.show()
```

In [389]:
```
cluster_results_empty = np.zeros(cluster_n_samples, dtype=int)
```

In [390]:
```
# Нет кластеров
visualize_clusters(cluster_dataset, cluster_results_empty)
```

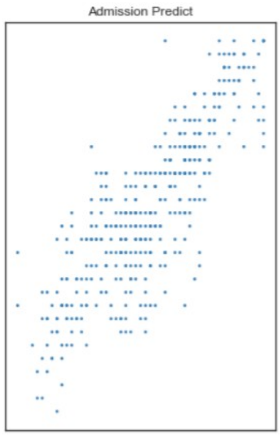

In [391]:
```
# Эталонные значения кластеров
visualize_clusters(cluster_dataset, cluster_true_y)
```

Метод К-средних (K-Means)

In [392]:
```
def do_clustering(cluster_datasets, method):
    """
    Выполнение кластеризации для данных
    """
    cluster_result = method.fit_predict(cluster_dataset)
    return cluster_result
```

In [393]:
```
result_KMeans_plus_3 = do_clustering(cluster_dataset, KMeans(n_clusters=3, init='k-means++'))
```

In [394]:
```
visualize_clusters(cluster_dataset, result_KMeans_plus_3)
```

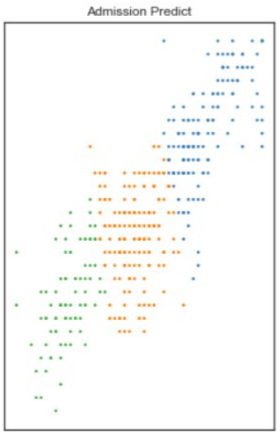

Подбор гиперпараметра

In [395]:
```
inertia = []
TEMP_X = cluster_dataset
for k in range(1, 7):
    kmeans = KMeans(n_clusters=k, random_state=1).fit(TEMP_X)
    inertia.append(np.sqrt(kmeans.inertia_))
plt.plot(range(1, 7), inertia, marker='s')
plt.xlabel('$k$')
plt.ylabel('$J(C_k)$')
```

Out[395]:
```
Text(0, 0.5, '$J(C_k)$')
```

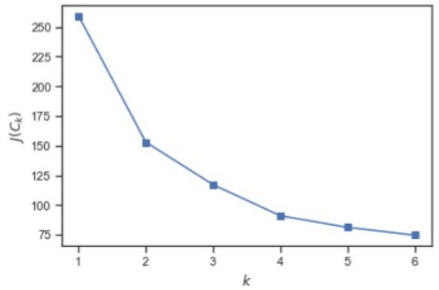

В качестве гиперпараметра K (количество кластеров) было выбрано число 3. Как видно по графику, после K = 2 уменьшение инерции замедляется.

Результат с количеством кластеров K = 2:

In [422]:
```
result_KMeans_plus_2 = do_clustering(cluster_dataset, KMeans(n_clusters=2, init='k-means++'))
```

In [423]:
```
visualize_clusters(cluster_dataset, result_KMeans_plus_2)
```

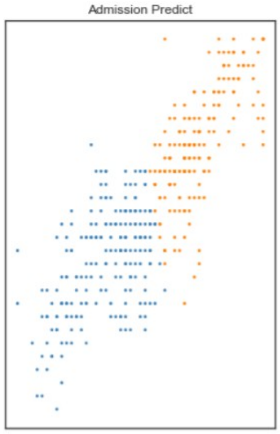

In [424]:
```
warnings.simplefilter(action='ignore', category=FutureWarning)

def claster_metrics(method, cluster_dataset, cluster_true_y, dataset_name):
    """
    Вычисление метрик кластеризации
    """
    temp_cluster = method.fit_predict(cluster_dataset)
    ari = adjusted_rand_score(cluster_true_y, temp_cluster)
    ami = adjusted_mutual_info_score(cluster_true_y, temp_cluster)

    h, c, v = homogeneity_completeness_v_measure(cluster_true_y, temp_cluster)

    sl = silhouette_score(cluster_dataset, temp_cluster)

    result = pd.DataFrame([{'Datasets':dataset_name,
                            'AMI':ami,
                            'Homogeneity':h,
                            'Completeness':c,
                            'V-measure':v,
                            'Silhouette':sl,
                            'ARI':ari}])
    return result
```

In [425]:
```
# Вычисление метрик для KMeans
claster_metrics(KMeans(n_clusters=2, init='k-means++'), cluster_dataset, cluster_true_y, dataset_name)
```

Out[425]:

	Datasets	AMI	Homogeneity	Completeness	V-measure	Silhouette	ARI
0	Admission Predict	0.269787	0.271706	0.270525	0.271114	0.535197	0.334735

DBSCAN

In [426]:
```
result_DBSCAN = do_clustering(cluster_dataset, DBSCAN(eps=1.45))
```

In [427]:
```
visualize_clusters(cluster_dataset, result_DBSCAN)
```

In [454]:
```
# Вычисление метрик для DBSCAN
claster_metrics(DBSCAN(eps=1.45), cluster_dataset, cluster_true_y, dataset_name)
```

Out[454]:

	Datasets	AMI	Homogeneity	Completeness	V-measure	Silhouette	ARI
0	Admission Predict	0.065772	0.083162	0.066629	0.073983	0.063001	0.051323

Метрики для оценки качества кластеризации:

Adjusted Rand Index – применяется, когда известны истинные метки классов. Отчасти метрика напоминает accuracy, так как сравнивает полученные метки классов с известными истинными классами.
Adjusted Mutual Information
Homogeneity - каждый кластер содержит только представителей единственного класса (под классом понимается истинное значение метки кластера).
Completeness - все элементы одного класса помещены в один и тот же кластер.
V-measure – среднее гармоническое от Homogeneity и Completeness.
Коэффициент силуэта – не требует знания истинных значений меток кластеров. Показывает, насколько среднее расстояние до объектов своего кластера отличается от среднего расстояния до объектов других кластеров.

Вывод:
Сравнивая полученные метрики двух алгоритмов кластеризации – K-Means и DBSCAN, можно сказать, что оба этих алгоритма далеки от идеальных для текущего датасета, но K-Means лучше справился с задачей разбиения исходного набора данных на кластеры.